


BANCA DATA MASTER

Case Engenharia de Dados

Apresentação para: Alexandre Carvalho - Daniel Faioli

Nome: Suellen Alves Gregorio



Índice

03	Visão Geral do Case	12	PySpark	20	Referência Bibliográfica
04	Objetivos e Métricas	13	Estrutura de Notebooks		
05	Modelo Conceitual	14	Delta Lake e Parquet		
06	Nível de Maturidade	15	Repositório		
07	Base de Dados	16	SDC		
08	Tecnologias Usadas	17	Segurança		
09	Databricks	18	Observabilidade		
10	Spark	19	Melhorias e Conclusão		

»»» Visão Geral

Este case de engenharia de dados tem como objetivo analisar o desempenho de vendas de 2011 e 2012 a partir de dados históricos, identificando padrões, tendências e oportunidades estratégicas. Utilizando a arquitetura Medallion (Bronze, Silver e Gold) com PySpark, Delta Lake e Databricks, o pipeline transforma dados brutos em informações valiosas para suportar decisões orientadas por dados. O resultado é um modelo robusto com tabelas fato e dimensões otimizadas para análises detalhadas por cliente, produto, fabricante, geografia, segmento, categoria e tempo.

>>> Objetivos e Métricas

- **Qual assunto será analisado? (Fato)**

Vendas

- **Como será analisado? (Dimensões/Granularidade)**

Produto, Segmento, Cliente, Tempo, Categoria, Fabricante e Geografia.

- **Quais são os indicadores? (KPI's)**

Total de vendas (quantidade e valor).

Variações de vendas (Diária / Mensal / Anual) quantidade e valor.

A variação compara o desempenho com o mesmo período anterior.

Ticket médio (quantidade e valor)

- **Quais as perguntas os dados devem responder?**

Qual estado tem o maior número de vendas no mês?

- **Aplicar regra de segurança? (RLS, DDM, CLS)**

O gerente só visualiza os dados de vendas do seu segmento


- **Qual o principal problema a ser resolvido?**

Gerar promoções no segmento que menos vende, com base em dados.

Modelo Conceitual – Snow Flake



Nível de Maturidade



Os estágios 1 e 2 são para relatórios/análise histórica ou para detectar tendências e padrões a partir do passado, o que a figura 1 “os chamou de espelho retrovisor”.

Figura 1: Estágios da maturidade de dados da empresa.

Base de Dados

As duas bases de dados e possuem a mesma estrutura de colunas e tipos de dados.

- Dados Fictícios
- Dados Estruturados
- Extração em Lote

Arquivo: dados_vendas_2011.csv

Tamanho: 20,5 MB

Quantidade de registros: 112.202

Arquivo: dados_vendas_2012.csv

Tamanho: 21,4 MB

Quantidade de Registros: 116.895

Tecnologias usadas

- Databricks - Como Plataforma
- Arquitetura Spark
- PySpark
- Arquitetura Medalhão
- Delta Lake
- SDC Nível 2
- Parquet


Databricks

Databricks é uma plataforma unificada baseada na **nuvem**, para processamento e análise de grandes volumes de dados. Foi projetada para facilitar o uso do Spark pelas empresas sem a necessidade de se preocupar com a configuração e a **manutenção da própria infraestrutura**, o que torna análise avançada de dados acessível para um conjunto mais amplo de usuários.

Sua arquitetura facilita o trabalho em ambientes de Big Data e inteligência artificial, sendo amplamente utilizada para acelerar projetos de dados em ambientes empresariais.

Para o desenvolvimento do Case, utilizei a versão **Community**
Criei um **Workspace** com **nove notebooks** no formato jupyter

Arquitetura Spark



Justificativa para o uso do Spark

Processamento de dados em larga escala com velocidades mais rápidas do que o Hadoop. Por dividir um processamento grande, distribuindo em tarefas menores entre os workers que retornam esses dados mais rápidos, que são compilados pelo gerenciador do cluster e devolve para a aplicação.

Permite executar tarefas complexas de processamento de dados.

Permite utilizar as linguagens de programação: **Java, Scala, Python e R.**

PySpark

O **PySpark** é uma biblioteca do Apache Spark para Python, voltada para o processamento **distribuído de dados**. Ela é ideal para trabalhar com grandes volumes de dados, pois permite o **processamento em larga escala** com alto desempenho.


Além disso, o PySpark pode ser utilizado em conjunto com outras bibliotecas do ecossistema Python, o que facilita a integração com ferramentas de análise e machine learning.

O uso do PySpark se justifica pela necessidade de tratar grandes conjuntos de dados de forma eficiente e escalável, aproveitando a capacidade de paralelização e distribuição de tarefas do Apache Spark.

Estrutura dos Notebook

- 000 Criando os Diretórios
- 001 Importando o Arquivo
- 002 Load Camada Bronze
- 003 Transformações Camada Silver
- 004 Load Camada Gold Delta
- 005 Load Gold Delta Incremental
- 006 Consultas Otimizadas
- 007 Criação de tabelas Delta
- 008 Rotinas de Manutenção Delta

Repositório GitHub



LINK

Delta Lake e Parquet

O **Delta Lake** é uma camada de armazenamento open source que roda sobre data lakes (como o Amazon S3, Azure Data Lake, Google Cloud Storage ou DBFS no Databricks) e que adiciona funcionalidades de confiabilidade e performance, como transações ACID, controle de versões e leitura eficiente. Ele é amplamente utilizado com o Apache Spark, principalmente dentro da plataforma Databricks.

Parquet – O que é e por que usar?

Parquet é um formato de arquivo colunar amplamente utilizado em big data. Ele é:

- Colunar: Ideal para leitura seletiva de colunas (economia de I/O).
- Compactado: Armazena dados comprimidos, otimizando espaço.
- Eficiente para leitura em cargas analíticas com Spark, Hive, Presto, etc.
- Suporta tipos complexos de dados, como arrays, structs e nested types.

Como Delta Lake e Parquet se relacionam?

- Os arquivos de dados no Delta Lake são Parquet, mas com um controle adicional por meio do `_delta_log`.
- O diretório de uma tabela Delta contém:
 - `bash`
 - `CopyEdit`
 - `/tabela_delta/`
 - `├── _delta_log/` ← metadados e logs de transação
 - `├── part-0001.parquet`
 - `└── part-0002.parquet`

SDC

Slowly Changing Dimensions

SCD Tipo 1: Não controla histórico

SCD Tipo 2: Controla o histórico

Surrogate Keys (SK) é uma chave artificial e auto incremental. O termo artificial vem do tipo, porque ela não existe em lugar nenhum, não está no banco relacional, ela é criada no Data Warehouse.

- É auto incremental.
- É utilizada para referenciar a dimensão na fato

Segurança

RLS - Row-Level Security (Segurança por Linha)

É uma funcionalidade que restringe o acesso a linhas específicas de uma tabela, com base na identidade do usuário que está executando a consulta.

DDM - Dynamic Data Masking (Mascaramento Dinâmico de Dados)

É uma técnica que mascara os dados sensíveis ao serem consultados, sem alterar os dados no banco.

CLS - Cell-Level Security (Segurança por Célula)

É uma segurança em nível de célula, onde é possível esconder valores específicos de medidas ou atributos, mesmo dentro de uma mesma linha.

LGPD (Lei Geral de Proteção de Dados Pessoais - Lei nº 13.709/2018)

Dados Pessoais: São informações relacionadas a uma pessoa natural identificada ou identificável. Exemplos: Nome completo, CPF, RG, Endereço, Telefone, e-mail.

Dados Pessoais Sensíveis São uma subcategoria de dados pessoais que revelam informações mais íntimas e, por isso, recebem um nível maior de proteção. Exemplos: Origem racial ou étnica, Convicção religiosa, Opinião política, Filiação a sindicato ou organização de caráter religioso, filosófico ou político, dado referente à saúde ou à vida sexual, Dado genético ou biométrico

Segurança

Mascaramento de dados na camada Silver

Esse trecho de código em PySpark está anonimizando os dados pessoais das colunas Nome e Email da tabela df_silver utilizando a função sha2, que aplica um hash criptográfico com o algoritmo SHA-256.

```
from pyspark.sql.functions import sha2, concat_ws

df_silver = df_silver.withColumn("Nome", sha2(col("Nome"), 256)) \
    .withColumn("Email", sha2(col("Email"), 256))

display(df_silver)
```

(1) Spark Jobs

df_silver: pyspark.sql.dataframe.DataFrame = [IDProduto: integer, Data: date ... 21 more fields]

	^A _C Email	^A _C Nome	^A _C TotalVendas
21	7e3b0460b5e4e821fdecc2084639b35ef3caf17806fd3a74a73d83c9d7863377	35e91f3f3d2de375506910f68232f1b637d8c6e4a934f80cbc068fb0b220efb9	124.42
22	f838e4cc7436696ec77689ecb22678ceebdc6a90a1dd8ca2e6d19e7b5642212e	7b6d644c0f764d33862a1c3bf2686200b87a1dee69367ce21425fc6eb0e0da4c	124.42
23	74be0261743d630879b694e4bb19a522477b7e5b57d0b3b42d237915f01855...	f10da66152da1fb41974ab55750554411146d394ec806e411618b70bc52aa901	124.42
24	48d9cca4da13c3de65d8ecaf15b28c6dff2d1a7c7058fef8b03b3d081d871ae	0ac9d1e10a7258beaceb04a23821123e795d0086d2ef94c41ca6b8a2fdbdf37e	124.42
25	acb006868dfc85a7fd5bb8f420419245466f66d0f4e5725b0a1dc265593dfdd3	0ec505cb17063bb49d62b745ebc237fcd055aa137edc5f7323c747f8648a2052	124.42
26	0d49fe560abc01e2fd66263b86a67e7af52e03e09832bab732d65ecd8ceacf8d	eb3a70072d5a8a7de6174dbfe32cee8f570cd9ece3f49642f9e53f3e9c0fe8fa	124.42
27	8601e4b0eb8a4ae55e79c6562985c20131ea86b92e6868a4febe94793241ce7b	acb5e3cbf1bb7147fa59f307eab07d99252bf48f16962c430e8b70391238c745	124.42
28	4bb502763b4272ea0ce5b361b50e555719979a11e1538e5c6a42ed82d3880ced	a0fc13b274bc4b9e0b1cdb0dc211f3566a2d3f1391c91d07fa623f7324ec2c64	124.42
29	44669daea055056764309c876f47d4e78251390e24e1938073d66cb178576203	0c9f05e1f80042144c7d954c7df8bf38a881b633593e191a941ab180d8c1de6c	124.42
30	65a0725a263dc67dcde90b100b3d56b6a7aa27e5eb202a30836b258998c42045	fb8b9d4cf2df26910a1ccbcbcd2e5acbe97afc2eab2c52ace59cd0d44afbba12e	124.42
31	cd4e8f9bd31dcde766f6f4ea4a455aeb719712bb3f8f4eb10e660f5631ff10de	138d6c53999050d159bc69adb5b9461d293a0824c3fab6a5575473805cfa302	124.42
32	c250b47c556bf9497d0bc3b5492d164808f430f8d1f99c5362c708e57af40e63	2ec036999ce291819e44ed9ae13cf5e19f38683b48e31733b0dcefd868f9e32e	124.42
33	9a8a2efeac4cba799ade1dd493b5ea9d1282d4e1b38706b6df6fdd9046363ba6	2db30c874b13a6703dc8ce12b8a284f7b1e6ab5ee93d39292d818a1d503665f4	124.42
34	927e4999fa95a09f7b5e84b9d9a04945c160da96b92f8f3031a06411ffaef60	fca6078e1db030c4820240dd37bb60549f88aed2c95ca0a605be9fc08357bdff	124.42

Observabilidade

Pilares da Observabilidade de dados

Atualização

Os dados são recentes? Qual a última vez que foram gerados? Quais dados de upstream são incluídos/omitidos?

Distribuição

Os dados estão dentro dos intervalos aceitos? Estão corretamente formatados? Estão completos?

Volume

Todos os dados chegaram?

Esquema

Qual é o esquema e como mudou? Quem fez essas mudanças e por quais motivos?

Linhagem

Quais são as fontes upstream e os ativos downstream impactados? Quem são as pessoas que geram esses dados e quem depende deles para a tomada de decisão

Fonte: (MOSES; GAVISH; VORWECK, 2024)

Observabilidade

▶

✓

1 minute ago (36s)

10

Python

🗑️

🔗

⋮

```
# Escrever a tabela no formato Parquet, particionando por DataVenda (ano e mês)
df_vendas.withColumn("Ano", year("Data")) \
    .withColumn("Mes", month("Data")) \
    .write.mode("overwrite").partitionBy("Ano", "Mes")
```

▼ (1) Spark Jobs

▶ Job 3 [View](#) (Stages: 1/1)

Jobs

Stages

Storage

Environment

Executors

SQL / DataFrame

JDBC/ODBC Server

Structured Streaming

Details for Job 3

Status: SUCCEEDED

Submitted: 2025/07/23 16:30:22

Duration: 19 s

Associated SQL Query: 5

Job Group: 6287388451541999878_8190323895478183029_992f69e8453b43e790769bc5ad1231c6

Completed Stages: 1

▶ Event Timeline

▶ DAG Visualization

▼ Completed Stages (1)

Page: 1 1 Pages. Jump to 1 . Show 100 items in a page. Go

Stage Id ▼	Pool Name	Description	Submitted	Duration	Tasks: Succeeded/Total	Input
4	6287388451541999878	# Escrever a tabela no formato Parquet, partici... parquet at NativeMethodAccessorImpl.java:0 +details	2025/07/23 16:30:22	19 s	6/6	

Melhorias e Considerações Finais

- Utilizar uma api para ingestão dos dados;
- Utilizar base de dados com estruturas diferentes;
- Explorar o armazenamento em um repositório fora;
- Criação de um Dashboard;

Referências Bibliográficas

MOSES, Barr; GAVISH, Lior; VORWECK, Molly. **Fundamentos da Qualidade de Dados**. Rio de Janeiro: Alta Books, 2024
SERRA, James. **Decifrando Arquitetura de Dados**. São Paulo: Novatec, 2024.